
Reliable Probabilistic Human Trajectory Prediction for Autonomous Applications

Manuel Hetzel , Hannes Reichert ¹, Konrad Doll , and Bernhard Sick

Thành viên nhóm

Huỳnh Thuý Minh Nguyệt

102220159

Nguyễn Thị Quỳnh Nha

102220201

Trần Công Toại

102220254




Table of Contents

01. *Bài toán & tổng quan mô hình*

02. *Nhiều chiều theo ba nghĩa*

03. *Dataset IMPTC*

04. *Vì sao cần một hỗn hợp*

05. *Kiến trúc & cách huấn luyện*

06. *Đánh giá: tin cậy và độ sắc*

07. *Baseline $M = 3$*


08. *Cải tiến: Sparsemax $K_{max} = 8$*

09. *Đóng góp, hạn chế & thảo luận*

1. Bài toán & tổng quan mô hình

Problem

- Human Trajectory Prediction (HTP) - dự đoán vị trí tương lai của người đi bộ, phục vụ cho xe tự hành (AV) và máy tự hành (AM).



Làm sao để dự đoán quỹ đạo kèm theo độ bất định

- Độ bất định đó ĐÁNG TIN về mặt thống kê
- Đủ nhẹ để chạy real-time trên phần cứng nhúng

Paper & Model Overview


Reliable Probabilistic Human Trajectory Prediction for Autonomous Applications

Manuel Hetzel¹, Hannes Reichert¹, Konrad Doll¹, and Bernhard Sick²

¹ University of Applied Sciences Aschaffenburg, Germany
{manuel.hetzel, hannes.reichert, konrad.doll}@th-ab.de

² University of Kassel, Germany
{bsick}@uni-kassel.de

- Stacked LSTM + Mixture Density Network (MDN) head → xuất ra hỗn hợp 3 Gaussian hai biến cho mỗi bước thời gian tương lai.




2. Nhiều chiều theo ba nghĩa

Tại sao đây là chuỗi thời gian nhiều chiều

- Nhiều chiều về không gian
- Nhiều chiều về đầu ra theo thời gian
- Nhiều chiều về phân bố
- Chiều thời gian có độ dài biến đổi

1 KHÔNG GIAN



mỗi mốc = một điểm $[x, y]$
x và y **TƯƠNG QUAN**



cần tham số p

2 THỜI GIAN




48 bước đầu ra cùng lúc
bất định TĂNG DẦN



cần mô hình chuỗi (LSTM)

3 PHÂN BỐ



tương lai tách **nhiều nhánh**
một Gaussian **KHÔNG** đủ



cần **HỖN HỢP (GMM)**

2. Nhiều chiều theo ba nghĩa


Phép biến đổi ego

- gọi φ_t là hướng di chuyển của VRU tại thời điểm hiện tại tại t
- Toàn bộ quỹ đạo (cả input và ground truth) được tịnh tiến về gốc tại vị trí hiện tại và xoay sao cho hướng đi trùng trục x

$${}^e p_{t+h} = R(-\varphi_t) \cdot ({}^w p_{t+h} - {}^w p_t)$$

dời gốc về vị trí hiện tại, rồi xoay ngược hướng đi

$$R(-\varphi_t) = \begin{bmatrix} \cos \varphi_t & \sin \varphi_t \\ -\sin \varphi_t & \cos \varphi_t \end{bmatrix} \quad \varphi_t = \text{hướng di chuyển tại thời điểm } t$$



$R(-\varphi_t)$
dời gốc
+ xoay



2. Nhiều chiều theo ba nghĩa

Các ký hiệu

- Một vị trí trong tọa độ thể giới (ký hiệu w):

$${}^w\mathbf{p}_t = [{}^w x_t, {}^w y_t]$$

- INPUT: quỹ đạo quá khứ trên observation horizon H_{in} . $H_{in} = \{0, -1, -2, \dots, -n\}$

$${}^wT_{in;t} = \left\{ {}^w\mathbf{p}_{t+h} \mid h \in H_{in} \right\}$$

- Nhãn (ground truth) - quỹ đạo tương lai trên forecast horizon.
 - Chỉ dùng trong hàm loss
 - $H_{fc} = \{1, 2, \dots, m\}$

$${}^wT_{gt;t} = \left\{ {}^w\mathbf{p}_{t+h} \mid h \in H_{fc} \right\}$$

3. Dataset IMPTC

**Dataset IMPTC -
Infrastructural Multi-
Person Trajectory and
Context Dataset**

- Nguồn: Hetzel và cộng sự, IEEE IV 2023 · giao lộ nội thành Đức
- Loại dữ liệu: Chuỗi thời gian đa biến, lấy mẫu đều
- Tần số: 25 Hz gốc → 10 Hz (Cubic Spline)
- Đơn vị quan sát: 1 mẫu = 1 cửa sổ 8 giây của một người đi bộ
- Kích thước mỗi mẫu: 80 bước × 4 chiều (32 vào + 48 ra)
- Tổng số mẫu: 265 437 trên 1 881 track

• **Dữ liệu sau tiền xử lý**



	kiểu	shape	dtype	giá trị
trường				
X	ndarray	(32, 4)	float64	
y	ndarray	(48, 4)	float64	
class	int	—	int64	0
reference_position	ndarray	(1, 2)	float64	[[18.82081483 -15.91850679]]
rotation_angle	float	—	float64	0.8014867935754699
movement_class	str	—	<U8	straight
avg_velocity	float	—	float64	1.4471269149527206
shift	int	—	int64	5
id	int	—	int64	2
source	str	—	<U19	imptc_0_00002_00005

	x (m, ngang)	y (m, dọc)	vx (m/s)	vy (m/s)
bước				
0	-0.0972	-4.5337	0.0190	1.4929
1	-0.0953	-4.3844	0.0190	1.4929
2	-0.0921	-4.2357	0.0316	1.4871
3	-0.0878	-4.0875	0.0432	1.4820
28	0.0418	-0.4196	-0.1041	1.4065
29	0.0296	-0.2797	-0.1225	1.3994
30	0.0156	-0.1400	-0.1393	1.3969
31	-0.0000	-0.0000	-0.1566	1.3995

3. Dataset IMPTC



Dataset IMPTC

mẫu imptc_0_00138_00123 — strong_left






3. Dataset IMPTC

Dataset IMPTC



4. Vì sao cần một hỗn hợp

- Về toán học: tính trung bình rơi vào chỗ ít khả năng nhất
- Về bản chất: chuyển động người vốn bất định - không có "một quỹ đạo đúng" để mà đo sai số
- Về ứng dụng: Xe tự hành cần **vùng**, không cần **điểm** - để tính xác suất va chạm



Đầu ra phải là một **phân bố đa mode**

4. Vì sao cần một hỗn hợp

- Mô hình không xuất tọa độ. Với mỗi $h \in H_{fc}$, nó xuất tham số của một hỗn hợp Gaussian

$$\mathcal{D}_{t+h}(\mathbf{p}_{t+h}) = \sum_{m \in M} c_{m:t+h} \cdot \mathcal{F}_{m;t+h}(\mathbf{p}_{t+h})$$


↓
mật độ tổng hợp
tại điểm p

↓
tổng qua
các mode


↓
trọng số của
mode m

↓
Mật độ Gaussian
của mode m

Sáu tham số của MỘT Gaussian hai biến




μ = tâm
nhánh này đi tới đâu



σ_x, σ_y = bán trục
bất định theo mỗi hướng



$\rho > 0$ — nghiêng ↗
x tăng thì y có xu hướng tăng



$\rho < 0$ — nghiêng ↘
x tăng thì y có xu hướng giảm

4. Vì sao cần một hỗn hợp

GMM là gì?

Gaussian Mixture Model — tổng có trọng số của nhiều Gaussian

$$p(y) = \sum_{k=1}^K \pi_k \mathcal{N}(y | \mu_k, \Sigma_k)$$

π_k


weight — mức độ quan trọng của mode

μ_k

mean — vị trí trung tâm

Σ_k

covariance — độ rộng & hướng lan




Mỗi Gaussian = một khả năng (mode)

4. Vì sao cần một hỗn hợp

Tại sao cần GMM cho quỹ đạo người?

Human trajectory thường multimodal



- 1 Multimodal**
Cùng một quá khứ → nhiều tương lai hợp lý: đi thẳng, rẽ trái, đổi hướng.
- 2 Point prediction**
Trung bình các khả năng → rơi vào vị trí không thực tế.
- 3 GMM**
Biểu diễn nhiều tương lai cùng lúc, mỗi mode có xác suất riêng.

5. Kiến trúc & cách huấn luyện

LSTM → MDN → GMM

Từ trajectory quá khứ đến phân phối xác suất tương lai



1 LSTM

Học thông tin theo thời gian từ chuỗi vị trí quá khứ

2 MDN

Dự đoán mixture parameters π, μ, Σ từ h_t


3 GMM

Biểu diễn nhiều khả năng tương lai cùng lúc

5. Kiến trúc & cách huấn luyện

LSTM là gì?

Long Short-Term Memory: mạng hồi quy (RNN) có bộ nhớ dài hạn cho dữ liệu chuỗi



Forget gate

Loại bỏ thông tin cũ không còn hữu ích



Input gate

Ghi thông tin mới vào cell state



Output gate

Chọn phần bộ nhớ xuất ra hidden state h_t


Vì sao dùng LSTM? RNN thường quên thông tin xa (vanishing gradient); nhờ các gate, LSTM giữ được bộ nhớ dài hạn, nên h_t tóm tắt tốt hướng đi và vận tốc của cả quỹ đạo quá khứ.

5. Kiến trúc & cách huấn luyện

MDN là gì?

Mixture Density Network — neural network dự đoán tham số của mixture distribution

$h_t \rightarrow \{\pi_k, \mu_k, \Sigma_k\}$ cho mỗi bước $t+1 \dots t+m$ ($K = 3$)



GMM mô hình hóa phân phối

MDN học cách dự đoán tham số của phân phối

5. Kiến trúc & cách huấn luyện

Công thức & NLL


Huấn luyện bằng Negative Log-Likelihood

MIXTURE DENSITY

$$p(y|x) = \sum_k \pi_k(x) \mathcal{N}(y|\mu_k(x), \Sigma_k(x))$$


LOSS

$$\mathcal{L}_{NLL} = -\log p(y_{true}|x)$$



$p(y_{true} | x)$ cao

→ **NLL thấp**



$p(y_{true} | x)$ thấp

→ **NLL cao**


6. Đánh giá: tin cậy và độ sắc

Confidence Set, Reliability & Sharpness

Làm sao biết dự đoán xác suất vừa đáng tin, vừa hữu ích?

Confidence set


Vùng $\Omega(1-\alpha)$ chứa người với xác suất $1-\alpha$. Tính bằng N mẫu lấy từ GMM.



Vùng 95%: chắc 95% người ở trong


Reliability

Đo tỉ lệ ground truth thực sự nằm trong $\Omega(1-\alpha)$ ở nhiều mức. Khớp với $1-\alpha \rightarrow$ calibrated tốt.



Sharpness


Diện tích của Ω ở mức 68% và 95% (S68, S95). Càng nhỏ càng sắc nét, càng hữu ích.



Tin cậy + sắc nét mới hữu ích

6. Đánh giá: tin cậy và độ sắc

Full Pipeline



Mô hình xác suất

Huấn luyện & đánh giá

GMM

Biểu diễn nhiều tương lai

MDN

Dự đoán tham số GMM

NLL

Huấn luyện xác suất

Calibration

Kiểm tra độ tin cậy

“Mô hình không chỉ dự đoán người có thể đi đâu, mà còn cho biết xác suất của từng khả năng và mức độ đáng tin của các xác suất đó.”

7. Baseline $M = 3$

Thực nghiệm baseline LSTM-MDN ($M = 3$)


- Dựa trên mã nguồn chính thức của paper, huấn luyện và đánh giá trên IMPTC
- Phạm vi thực nghiệm
 - Mục tiêu: dự đoán phân phối vị trí người đi bộ trong 4,8 giây tới.
 - Đầu vào 3,2 giây $\rightarrow$ LSTM $\rightarrow$ MDN $\rightarrow$ 3 Gaussian / thời điểm.
 - Đã hoàn thành 2.500 epoch; chọn checkpoint theo validation NLL.
 - Cơ sở để so sánh cải tiến: cùng dữ liệu, protocol và metric.

Baseline đã học như thế nào?


Training & validation NLL · M = 3

Best: epoch 1.961 · validation NLL = -1,150

Entire training history (epochs 1-2500)




Later training (epochs 100-2500)



Cùng một mẫu qua các checkpoint


Chỉ prediction thay đổi



Observed và ground truth giữ nguyên; so sánh đường trung bình của GMM.




Ba Gaussian trông như thế nào?

Một mẫu · một thời điểm $t = 3,0$ s



Dự đoán tốt và trường hợp khó

Đọc kết quả trên fixed samples




Thấp / giữa / cao trong 8 mẫu cố định; không đại diện toàn bộ tập test.

Bất định theo thời gian dự đoán


Vùng tin cậy của GMM từ output thực

GMM confidence regions across the forecast horizon
Actual M=3 best-checkpoint output · monotonic expansion



Dự đoán có đáng tin cậy không?

Calibration trên toàn bộ test



Đường chéo:
coverage = mức tin cậy

Ravg $\approx$ 97,47%
Rmin $\approx$ 94,06%

Độc cùng sharpness:
vùng quá rộng có thể bảo thủ.

Kết quả test của baseline M = 3

Checkpoint best - test đầy đủ


Chỉ số	Baseline M = 3	Diễn giải
Test NLL	-1,092	Log mật độ: thấp hơn tốt hơn
minADE ₂₀ / minFDE ₂₀	0,464 / 0,607 m	Sai số tốt nhất trong 20 mẫu
Ravg / Rmin	97,47% / 94,06%	Reliability theo định nghĩa paper
S ₆₈ / S ₉₅	1,358 / 6,061 m ² /s	Sharpness; đọc cùng reliability
ASAEE	0,235 m/s	Metric lưu bởi bộ đánh giá

8. Cải tiến: Sparsemax $K_{\max} = 8$


Ý tưởng

Chỉ khối chuẩn hóa π bị thay đổi; mọi thứ khác (LSTM, μ , σ , ρ , loss NLL, optimizer, lịch học) giữ nguyên

Baseline



sparsemax_mdn




Softmax: $\pi > 0 \rightarrow$ mọi component còn trong mixture; Sparsemax: π có thể = 0.

$K(x,t)$ thay đổi theo mẫu và horizon; $K_{\max} = 8$ vẫn là giới hạn đặt trước.

Đổi chuẩn hóa π ; giữ LSTM, mục tiêu NLL và công thức μ , σ , ρ .

Kết quả test: tốt hơn ở 6 metric






Metric	K=3	Kmax=8
NLL ↓	-1,092	-1,121
Ravg ↑	97,47	98,07
Rmin ↑	94,06	95,66
S68 ↓	1,358	1,148
S95 ↓	6,061	7,034
minADE20 ↓	0,464	0,457
minFDE20 ↓	0,607	0,595
ASAE ↓	0,235	0,239

↑ cao hơn tốt hơn; ↓ thấp hơn tốt hơn.
R: % · S: m²/s · ADE/FDE: m · ASAE: m/s

Mức dùng thành phần trên toàn bộ validation

K thay đổi theo mẫu và horizon

Phân tích thật trên 19148 mẫu validation, checkpoint best epoch 1961 (khám phá, chỉ validation)




Validation: K trung bình 3,27 · Test: 3,29 · K hoạt động từ 1 đến 8.

$K(x,t)$ = số trọng số $\pi > 0$; không tự động có nghĩa suy luận nhanh hơn.

S95 xấu hơn: đuôi cực trị chỉ phôi

Giới hạn

Phân rã điểm S95 trên tập test: sparsemax K_max = 8 so với baseline K = 3



(c) Thành phần của mẫu rộng nhất [thật]

Mẫu test #7589 tại 2.4 s (vận tốc cuối 0.79 m/s)

sparsemax K_max=8: vùng 95% = 1126 m²

$\pi=0.522$ $\sigma=(0.99; 0.92)$ m
 $\pi=0.318$ $\sigma=(11.97; 16.98)$ m
 $\pi=0.160$ $\sigma=(1.92; 3.22)$ m

baseline K=3: vùng 95% = 3 m²

$\pi=0.704$ $\sigma=(0.28; 0.49)$ m
 $\pi=0.282$ $\sigma=(0.21; 0.12)$ m
 $\pi=0.014$ $\sigma=(2.49; 3.35)$ m

Hai phần là hai phần đóng góp vào điểm S95 (trung bình 101 phân vị của diện tích vùng tin cậy theo mẫu, ở mỗi mốc), không phải hai vùng của Gaussian.

9. Đóng góp, hạn chế & thảo luận

Đóng góp

- Tái lập đầy đủ baseline $M = 3$ trên IMPTC
 - 2 500 epoch. Chọn checkpoint theo validation NLL. R_{avg} 97,47 %. R_{min} 94,06 %. minADE 0,464 m
- Thay softmax bằng SPARSEMAX, $K_{max} = 8$
 - Mô hình TỰ CHỌN số thành phần thay vì cố định bằng tay
 - K trung bình 3,27
 - Tốt hơn ở 6/8 chỉ tiêu

Hạn chế

- S95 xấu đi (6,061 → 7,034) do một số mẫu cực đoan chi phối
- Không dùng ngữ cảnh (bản đồ, đèn giao thông)

Thảo luận

- Reliability và Sharpness là hai trục độc lập - cải thiện một trục không bảo đảm trục kia
- Số mode cần thiết KHÔNG phải hằng số
- Hướng tiếp: lưới $K_{max} \times hidden_size$ và đánh giá trên ETH/UCY

Thank you for listening